第一章 Linear Regression——线性回归

Linghao CHEN

2021 年 10 月 21 日

1 简介

我们首先介绍什么是线性回归。当线性数据中的输入和输出有很强的线性相关性时，人们希望挖掘出这种相关性的准确数学表达。这一过程就是线性回归的过程。我们来看一组数据：

表 1: 数据样例

样本标号	**1**	**2**	**3**	**4**	**5**	**6**
x_1	1.3	1.5	3.6	4.4	5.6	7
x_2	2.8	2.4	3.2	3.9	6	7.2
y	6.9	6.5	9.7	11	17.5	21.1

通过观察，我们不难发现，数据的输入 $\mathbf{x} = (x_1, x_2)^T$ 和输出 y 是有很强的线性相关性的，他们之间的关系大致满足 $y \approx x_1 + 2x_2$。当我们挖掘到这一相关性之后，我们就可以使用这个公式来预测：当输入数据为表中没有出现的取值时，输出 y 的取值为多少。

在现实生活中，就有一个非常经典的数据集——波士顿房价预测数据集。这个数据集中，这个数据集的自变量（一氧化氮浓度、犯罪率等指标）和因变量（房价）之间有很强的相关性。在该数据集上，我们就可以通过这些给出的数据来拟合房价和自变量各项指标之间的关系，进而进行房价预测。

2 模型的形式化描述

【模型的训练数据】：

模型一共有 n 个训练样本，第 i $(i = 1, 2, ..., n)$ 个训练样本为为一个 d 维的向量：$\mathbf{x}^{(i)} = (x_1^{(i)}, ..., x_{d-1}^{(i)}, x_d^{(i)})^T \in \mathbb{R}^d$，其中 $x_j^{(i)}$ 表示的是第 i 个样本的第 j 个属性；$y^{(i)} \in \mathbb{R}$ 表示其对应的预测值。由 n 个样本构成的数据集自变量集合为：$\mathcal{X} = \{\mathbf{x}^{(i)}\}_{i=1}^n$，预测值集合为 $\mathcal{Y} = \{y^{(i)}\}_{i=1}^n$。

【模型的返回结果】:

$\mathbf{x}$ 和 y 之间的线性关系：$y = b + \sum_{j=1}^{d} w_j x_j = \mathbf{w}^T \mathbf{x} + b$。其中 b 和 $w_j (j = 1, 2, ..., n)$ 都是需要学习的参数，b 是常数项。

3 模型的简化描述

对于我们需要学习的模型：$y = b + \sum_{j=1}^{d} w_i x_j$，任意的 $x_j (j = 1, 2, ..., n)$ 都表示训练数据的维度。我们不妨在向量 $\mathbf{x}$ 的第 0 维插入一个标量 1，新的 $\mathbf{x}^{(i)} = (x_1^{(i)}, ..., x_{d-1}^{(i)}, x_d^{(i)})^T \in \mathbb{R}^{d+1}$，同时我们令 $w_0 = b$。这样，我们就可以将这个线性模型写成：$y = \sum_{j=0}^{d} w_j x_j = \mathbf{w}^T \mathbf{x}$。这时，我们需要学习的参数就变成了向量：$\mathbf{w} = (w_0, w_1, ..., w_{d-1}, w_d)^T \in \mathbb{R}^{d+1}$。通过这种方式，我们就避免去分别求解常数项系数和一次项系数了。

4 求解

4.1 最小二乘法

4.1.1 低维的问题——标量求解方法

我们首先通过一种特殊的情况来了解最小二乘法。假设我们的需要拟合的模型是单变量的，那么我们所需要拟合的函数可以表达为：$y = w_0 + w_1 x_1$。我们希望对于任意的第 i 个样本，都尽量满足：$y^{(i)} \approx w_0 + w_1 x_1^{(i)}$。如果约等号的左右越接近，说明我们的模型拟合地越好。因此，我们可以得到我们需要最小化的目标函数 $\mathcal{L}(w_0, w_1)$：

$$\min \mathcal{L}(w_0, w_1) = \frac{1}{2n} \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x_1^{(i)})]^2 \tag{1}$$

上式表示的是所有样本的均方误差（Mean Square Error, MSE），除去 $2n$ 中的数字 2 是为了后续二次项求导的时候可以消去。由于上式中 $x_1^{(i)}$ 的下标 1 表示的是数据的第 1 个维度。因此为了方便描述，我们在下面的描述过程中将省略这个下标。这时候上式可以表示为：$\min \frac{1}{2n} \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x^{(i)})]^2$。我们需要求解的优化参数可以表示为：

$$w_0^\star, w_1^\star = \arg\min_{w_0, w_1} \frac{1}{2n} \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x^{(i)})]^2 \tag{2}$$

为了求得最优的 w_0, w_1 的取值，我们求 $\mathcal{L}(w_0, w_1)$ 对 w_0 的偏导数：

$$
\begin{aligned}
\frac{\partial \mathcal{L}(w_0, w_1)}{\partial w_0} =& \frac{1}{2n} \cdot \sum_{i=1}^{n} \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]^2}{\partial w_0} \\
=& \frac{1}{2n} \cdot \sum_{i=1}^{n} \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]^2}{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]} \cdot \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]}{\partial w_0} \\
=& \frac{1}{n} \cdot \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x^{(i)})] \cdot (-1) \\
=& -\frac{1}{n} \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x^{(i)})]
\end{aligned} \tag{3}
$$

求 $\mathcal{L}(w_0, w_1)$ 对 w_1 的偏导数

$$
\begin{aligned}
\frac{\partial \mathcal{L}(w_0, w_1)}{\partial w_1} =& \frac{1}{2n} \cdot \sum_{i=1}^{n} \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]^2}{\partial w_1} \\
=& \frac{1}{2n} \cdot \sum_{i=1}^{n} \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]^2}{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]} \cdot \frac{\partial [y^{(i)} - (w_0 + w_1 x^{(i)})]}{\partial w_1} \\
=& \frac{1}{n} \cdot \sum_{i=1}^{n} [y^{(i)} - (w_0 + w_1 x^{(i)})] \cdot (-x^{(i)}) \\
=& -\frac{1}{n} \sum_{i=1}^{n} [x^{(i)} y^{(i)} - (w_0 x^{(i)} + w_1 x^{(i)2})]
\end{aligned} \tag{4}
$$

分别令 $\frac{\partial \mathcal{L}(w_0, w_1)}{\partial w_0} = 0, \frac{\partial \mathcal{L}(w_0, w_1)}{\partial w_1} = 0$，可得：

$$
\begin{aligned}
w_1^\star =& \frac{\sum_{i=1}^{n} x^{(i)} \sum_{i=1}^{n} y^{(i)} - n \sum_{i=1}^{n} x^{(i)} y^{(i)}}{(\sum_{i=1}^{n} x^{(i)})^2 - n \sum_{i=1}^{n} x^{(i)2}}, \\
w_0^\star =& \bar{y} - w_1^\star \bar{x}
\end{aligned} \tag{5}
$$

其中 $(\bar{x}, \bar{y})$ 是样本中心点。详细推导过程见附录A。

【问题】：

Q：你如何判断这个 $w_0^\star, w_1^\star$ 求出来是最小值点，而不是极值点呢?

A：可以求二阶偏导数，根据二元函数凹凸性判断法则，目标函数 $\mathcal{L}(w_0, w_1)$ 是凸函数。

4.1.2 更通用的求解方法

基于上面的描述，我们已经对最小二乘法的基本求解思路有了一定的了解，下面我们需要将维度扩展到到更高维的空间中，得到更一般的解。我们希望通过训练求解出向量：

$\mathbf{w} = (w_0, w_1, ..., w_{d-1}, w_d)^T \in \mathbb{R}^{d+1}$。首先构造由 n 个训练数据构成的矩阵 X：

$$X = \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_d^{(1)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 1 & x_1^{(n)} & x_2^{(n-1)} & \cdots & x_d^{(n-1)} \\ 1 & x_1^{(n)} & x_2^{(n)} & \cdots & x_d^{(n)} \end{pmatrix} \in \mathbb{R}^{n\times(d+1)} \tag{6}$$

这个矩阵的每一行表示一个训练样本，一共有 n 个；每一列表示数据在各个维度的取值，第一列的 1 与常数项参数相乘，这个细节在第三小节“模型的简化描述”中已经进行了交代。

因此我们的训练目标是：$\mathbf{y} \approx X\mathbf{w}$，其中 $\mathbf{y} \in \mathbb{R}^n$ 表示的是 n 个样本的标签构成的向量。优化目标可以表达为：

$$\min \mathcal{L}(\mathbf{w}) = ||\mathbf{y} - X\mathbf{w}||_2^2 \tag{7}$$

其中 $||\cdot||_2$ 表示向量的 2-范数。我们需要求解的参数向量为：

$$\mathbf{w}^\star = \arg\min_{\mathbf{w}} ||\mathbf{y} - X\mathbf{w}||_2^2 \tag{8}$$

类似地，我们需要对其求导：

$$\begin{aligned} \frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} =& \frac{\partial ||\mathbf{y} - X\mathbf{w}||_2^2}{\partial \mathbf{w}} \\ =& \frac{\partial (\mathbf{y} - X\mathbf{w})^T(\mathbf{y} - X\mathbf{w})}{\partial \mathbf{w}} \\ =& \frac{\partial (\mathbf{y}^T - \mathbf{w}^T X^T)(\mathbf{y} - X\mathbf{w})}{\partial \mathbf{w}} \\ =& \frac{\partial (\mathbf{y}^T\mathbf{y} - \mathbf{w}^T X^T\mathbf{y} - \mathbf{y}^T X\mathbf{w} + \mathbf{w}^T X^T X\mathbf{w})}{\partial \mathbf{w}} \end{aligned} \tag{9}$$

由于 $\mathbf{w}^T X^T\mathbf{y}$ 和 $\mathbf{y}^T X\mathbf{w}$ 均是标量，标量的转置还是标量本身，所以我们有：$\mathbf{w}^T X^T\mathbf{y} = \mathbf{y}^T X\mathbf{w}$。因此有：

$$\begin{aligned} \frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} =& \frac{\partial (\mathbf{y}^T\mathbf{y} - \mathbf{w}^T X^T\mathbf{y} - \mathbf{y}^T X\mathbf{w} + \mathbf{w}^T X^T X\mathbf{w})}{\partial \mathbf{w}} \\ =& \frac{\partial (-2\mathbf{w}^T X^T\mathbf{y} + \mathbf{w}^T X^T X\mathbf{w})}{\partial \mathbf{w}} \\ =& -2X^T\mathbf{y} + X^T X\mathbf{w} + (X^T X)^T\mathbf{w} \\ =& -2X^T\mathbf{y} + 2X^T X\mathbf{w} \end{aligned} \tag{10}$$

这里运用了两个求导公式：

$$\begin{aligned} \frac{\partial \mathbf{w}^T\mathbf{x}}{\partial \mathbf{w}} &= \mathbf{x} \\ \frac{\partial \mathbf{w}^T X\mathbf{w}}{\partial \mathbf{w}} &= (X + X^T)\mathbf{w} \end{aligned} \tag{11}$$

公式11的证明详见附录B。

我们令 $\frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} = \mathbf{0}$，当 $X^T X$ 可逆时，我们有：

$$\begin{aligned} & -2X^T\mathbf{y} + 2X^T X\mathbf{w} = 0 \\ \Longrightarrow\ & X^T X\mathbf{w} = X^T\mathbf{y} \\ \Longrightarrow\ & \mathbf{w}^\star = (X^T X)^{-1} X^T\mathbf{y} \end{aligned} \tag{12}$$

【问题】：

Q：你如何判断这个 $\mathbf{w}^\star$ 求出来是最小值点，而不是极值点呢?

A：可以求二阶导数（叫做 Hessian 矩阵）$\frac{\partial^2 \mathcal{L}(\mathbf{w})}{\partial \mathbf{w} \partial \mathbf{w}^T} = 2X^T X$，为半正定（Hessian 矩阵的二次型为 $2\mathbf{v}^T X^T X\mathbf{v} = 2(X\mathbf{v})^T (X\mathbf{v}) = 2||X\mathbf{v}||_2^2 \geq 0$），目标函数 $\mathcal{L}(\mathbf{w})$ 是凸函数。

到这里为止，我们就从两个角度介绍完了最小二乘法的推导步骤，这样求出来的是解析解。下面需要给大家提供一种新的求解方式，这种算法是目前绝大多数深度学习技术的关键算法。

4.2 使用梯度下降法求解

在介绍这个算法前，默认大家已经了解什么是梯度了：沿梯度方向增长最快、沿梯度反方向减少最快。梯度下降法的思路是，通过多轮迭代来优化模型参数，每轮迭代都让参数沿梯度反方向迈进。其公式描述为：

$$\mathbf{w}^{r+1} := \mathbf{w}^r - \eta \frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}}|_{\mathbf{w}=\mathbf{w}^r} \tag{13}$$

其中 η 叫做学习率，表示的是每一步朝着梯度方向迈进时的步长，如果步长太长可能不收敛，如果太短，可能收敛地很慢，是我们需要精心设置的超参数。这里的梯度为：$\frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} = -2X^T\mathbf{y} + 2X^T X\mathbf{w}$。

由于目标函数是凸函数，我们可以在经过 R 轮迭代之后使模型收敛，得到最后的解。

A $w_0^\star, w_1^\star$ 的求解步骤

求解 w_0, w_1 解的步骤：

$$\begin{aligned}
\frac{\partial \mathcal{L}(w_0,w_1)}{\partial w_0}=0 &\implies -\frac{1}{n}\sum_{i=1}^{n}[y^{(i)}-(w_0+w_1x^{(i)})]=0 \\
&\implies \sum_{i=1}^{n}y^{(i)}=n\cdot w_0+w_1\sum_{i=1}^{n}x^{(i)} \\
\frac{\partial \mathcal{L}(w_0,w_1)}{\partial w_1}=0 &\implies -\frac{1}{n}\sum_{i=1}^{n}[x^{(i)}y^{(i)}-(w_0x^{(i)}+w_1x^{(i)2})]=0 \\
&\implies \sum_{i=1}^{n}x^{(i)}y^{(i)}=\sum_{i=1}^{n}(w_0x^{(i)}+w_1x^{(i)2}) \\
&\implies \sum_{i=1}^{n}x^{(i)}y^{(i)}=w_0\sum_{i=1}^{n}x^{(i)}+w_1\sum_{i=1}^{n}x^{(i)2}
\end{aligned} \tag{14}$$

联立两式：

$$\begin{aligned}
\sum_{i=1}^{n}y^{(i)}&=n\cdot w_0+w_1\sum_{i=1}^{n}x^{(i)} \\
\sum_{i=1}^{n}x^{(i)}y^{(i)}&=w_0\sum_{i=1}^{n}x^{(i)}+w_1\sum_{i=1}^{n}x^{(i)2}
\end{aligned} \tag{15}$$

得到：

$$w_1^\star=\frac{\sum_{i=1}^{n}x^{(i)}\sum_{i=1}^{n}y^{(i)}-n\sum_{i=1}^{n}x^{(i)}y^{(i)}}{(\sum_{i=1}^{n}x^{(i)})^2-n\sum_{i=1}^{n}x^{(i)2}} \tag{16}$$

注意到方程组中 $\sum_{i=1}^{n}y^{(i)}=n\cdot w_0+w_1\sum_{i=1}^{n}x^{(i)}$ 可以改写成 $\frac{1}{n}\sum_{i=1}^{n}y^{(i)}=w_0+w_1\frac{1}{n}\sum_{i=1}^{n}x^{(i)}$，即 $\bar{y}=w_0+w_1\bar{x}$。这意味着这条直线过样本中心点，因此可以根据 $w_1^\star$ 求出 $w_0^\star$。

B 对公式11的证明

B.1 证明 $\frac{\partial \mathbf{w}^T\mathbf{x}}{\partial \mathbf{w}}=\mathbf{x}$

公式中，$f(\mathbf{x})=\mathbf{w}^T\mathbf{x}\in\mathbb{R}$，其中 $\mathbf{x}=(x_1,x_2,...,x_d)^T\in\mathbb{R}^d, \mathbf{w}=(w_1,w_2,...,w_d)^T\in\mathbb{R}^d$。因此:

$$f(\mathbf{w})=\mathbf{w}^T\mathbf{x}=w_1x_1+w_2x_2+...+w_dx_d=\sum_{i=1}^{d}w_ix_i. \tag{17}$$

按元素求导，得：

$$\begin{aligned}
(\frac{\partial \mathbf{w}^T\mathbf{x}}{\partial \mathbf{w}})_i=\frac{\partial f(\mathbf{w})}{\partial w_i}=\frac{\partial \sum_{i=1}^{d}w_ix_i}{\partial w_i}=x_i \\
\implies \frac{\partial \mathbf{w}^T\mathbf{x}}{\partial \mathbf{w}}=\mathbf{x}.
\end{aligned} \tag{18}$$

B.2 证明 $\frac{\partial \mathbf{w}^T X \mathbf{w}}{\partial \mathbf{w}} = (X + X^T)\mathbf{w}$

记方阵 $\mathbf{X} \in \mathbb{R}^{d \times d}$ 第 i 行第 j 列的元素为 $x_{i,j}$，$\mathbf{w} = (w_1, w_2, ..., w_d)^T \in \mathbb{R}^d$。因此 $\mathbf{Xw} \in \mathbb{R}^d$，且：

$$\begin{aligned} f(\mathbf{w}) = \mathbf{w}^T X \mathbf{w} &= \sum_{k=1}^{d} w_k \sum_{j=1}^{d} x_{k,j} w_j \\ &= \sum_{k=1}^{d} \sum_{j=1}^{d} w_k x_{k,j} w_j \ \in \mathbb{R}. \end{aligned} \tag{19}$$

求导，得：

$$\begin{aligned} (\frac{\partial \mathbf{w}^T X \mathbf{w}}{\partial \mathbf{w}})_i &= \frac{\partial f(\mathbf{w})}{\partial w_i} = \frac{\partial \sum_{k=1}^{d} \sum_{j=1}^{d} w_k x_{k,j} w_j}{\partial w_i} \\ &= \sum_{j=1}^{d} w_j x_{i,j} + \sum_{j=1}^{d} w_j x_{j,i} \\ \Longrightarrow \frac{\partial \mathbf{w}^T X \mathbf{w}}{\partial \mathbf{w}} &= (X + X^T)\mathbf{w}. \end{aligned} \tag{20}$$

特别地，当 $X = X^T$ 时，$\frac{\partial \mathbf{w}^T X \mathbf{w}}{\partial \mathbf{w}} = 2X\mathbf{w}$。